


Beadandó dolgozat

Github repository(public): <https://github.com/rohalytomi/Hitelek-s-kock-zatok.git>


1.feladat

Az általunk választott két ETF a DBA (Invesco DB Agriculture Fund) és BND (Vanguard Total Bond Market Index Fund), kiszámoltuk az eszközök napi hozamait majd a portfólió hozamot adott dátumok között (2007 és 2022) és ennek segítségével számoltunk historikus VaR-t. Azt láttuk, hogy a súlyok módosításával (Weight1: 'dba': 0.2, 'bnd': 0.8, Weight2: 'dba': 0.4, 'bnd': 0.6, Weight3: 'dba': 0.6, 'bnd': 0.4, Weight4: 'dba': 0.8, 'bnd': 0.2), ahogy növeljük a BND arányát a portfólióban, úgy csökken a VaR értéke, azaz csökkent a maximális várható veszteség a megadott 0,95-ös szignifikancia szinten.

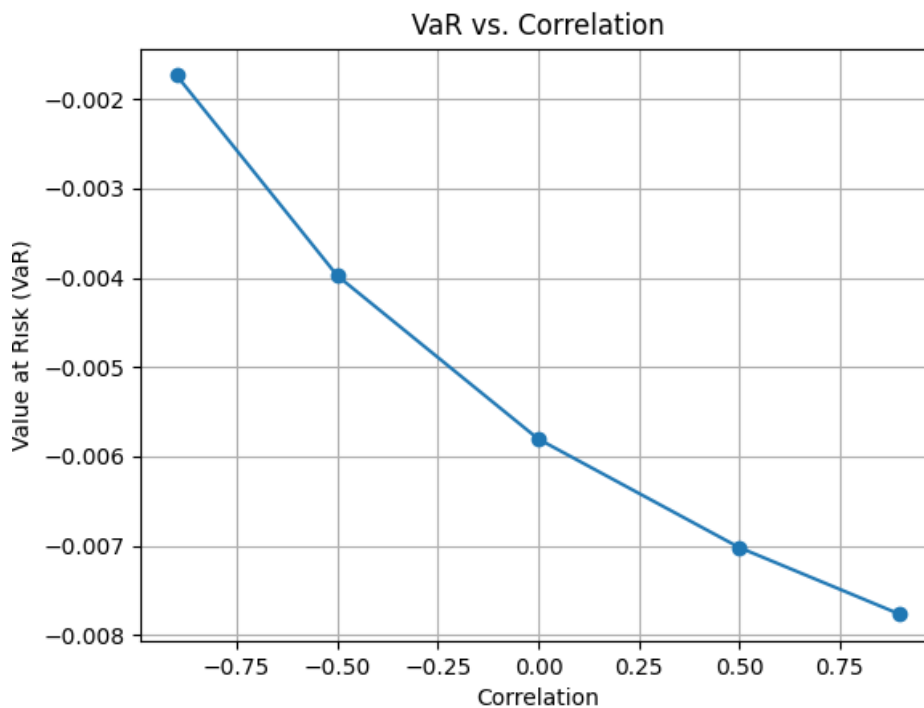


2. feladat

Ebben a feladatban is a korábban használt két ETF-et vettük alapul. Felhasználtuk a historikus hozamaikat és volatilitásukat a jövőbeli hozamok szimulálására. A portfólión belüli súlyokat a feladatban leírt módon a volatilitások inverz arányában határoztuk meg. Ezt követően megnéztük, hogy a különböző korrelációs feltevések mellett, hogyan alakulnak a hozamok és VaR értékek.



Azt láthatjuk, amit előre is feltételezhettünk, hogy a nagyobb korrelációnál kevésbé szóródnak a hozamok.




A VaR és a korreláció viszonyát tekintve, azt mondhatjuk, hogy minél nagyobb a korreláció, tehát minél jobban együtt mozog a két eszköz, annál kisebb a maximális várható veszteség értéke, ellenben, ha ellentétes irányba mozognak az növeli ezt az értéket.


3.feladat

Az EWMA módszer azt feltételezi, hogy a múltbeli adatok relevanciája az előrejelzett jövőbeli variancia csökkenésével exponenciálisan csökken. Az EWMA ezen tulajdonsága lehetővé teszi a volatilitás csoportosulás jelenségének megragadását, amely gyakori a pénzügyi idősorokban - a magas volatilitás időszakai általában magas volatilitást követnek, és fordítva.

Gyakorlatban a lecsengési tényező λ választása létfontosságú. A kockázatkezelés vezető szolgáltatója, a RiskMetrics, azt javasolja, hogy a napi értékrizikó (VaR) számításához használjunk 0,94 értékű λ -t.

Gyakorlati szempontból minél nagyobb a lecsengési tényező, annál nagyobb hangsúlyt kapnak a legutóbbi adatpontok. $\lambda = 0,94$ esetén a korábbi adatok súlyai nagyon gyorsan csökkennek, ami azt jelenti, hogy a régebbi múlt (például több mint 100 napja) hatása az aktuális varianciára elhanyagolható. Ezért az EWMA gyakorlati megvalósításában általában egy 100 napos gördülő ablakot használnak.





Elméletben a nagyobb lecsengési tényező, nagyobb hangsúlyt fektet a korábbi adatokra, ellenben a mi esetünkben a 0,94 és 0,97 lecsengési tényező közötti eltérés szabad szemmel nem látható a 100-as gördülő ablak alkalmazása mellett.


4. feladat

A kapott eredmények alapján a legjobb modell egy lineáris regresszió modellel érhető el 1. szabadságfokkal, ami azt jelenti, hogy egyszerű lineáris kapcsolat van a korábbi négyzetes hozamok és a tényleges négyzetes hozamok között.


A legjobb modell MSE (Mean Squared Error, átlagos négyzetes hiba) értéke közel $4.692e-09$. Egy alacsonyabb MSE jobb illeszkedést jelent a modellnek adatainkhoz, így ez arra utal, hogy a modell jól teljesít a jövőbeli variancia előrejelzésében a korábbi négyzetes hozamok alapján.

A legjobb modell koefficiensei a korábbi négyzetes hozamok és a tényleges négyzetes hozamok közötti kapcsolatot jelzik. A koefficiensek a súlyokat jelentik, amelyeket minden korábbi négyzetes hozamjellemző kap. Ebben az esetben a koefficiensek: $[0.5114, 0.2701, -0.2355, -0.1252, 0.1349, 0.1562, 0.0139, -0.1809, 0.1215, 0.039, 0.0077, -0.0865, 0.0387, 0.0162, 0.0076, 0.0457, 0.0338, -0.0736, 0.0559, -0.0195]$. Ezek a koefficiensek azt jelzik, hogy mennyire járul hozzá a korábbi négyzetes hozamjellemzők a jövőbeli variancia előrejelzéséhez. A pozitív koefficiensek pozitív kapcsolatot jelentenek, míg a negatív koefficiensek negatív kapcsolatot jeleznek.

A legjobb modell elfogadási értéke körülbelül $2.099e-06$. Ez az előrejelzett négyzetes hozam értéke, amikor minden korábbi négyzetes hozamjellemző nulla.



Az ábra összehasonlítja a tényleges és az előrejelzett négyzetes hozamokat az idő függvényében. A vonalak közötti különbség azt mutatja, hogy mennyire jól teljesít a modell az előrejelzésben. Az ábrán látható, hogy az előrejelzett értékek közel esnek a tényleges értékekhez, ami azt jelzi, hogy a modell jól képes becsülni a jövőbeli varianciát a korábbi négyzetes hozamok alapján.



Az ábra bemutatja a korábbi négyzetes hozamokat a késleltetett hozamok függvényében. Ez lehetővé teszi számunkra, hogy vizuálisan értékeljük a korábbi négyzetes hozamok idősorát és azok hatását a jövőbeli variancia előrejelzésére. Az ábrán látható, hogy az értékek változnak az idővel, és ezeket a változásokat a modell felhasználhatja a variancia előrejelzésére.

A második modell, amit a hiperparaméter keresés során találtunk, szintén foka 1, alacsonyabb, $8.6495794895754e-10$ MSE értéket ér el. Ez azt jelenti, hogy a modell jobban illeszkedik a tesztadatokhoz és pontosabban becsüli meg a négyzetes visszatéréseket. Legjobb modell együtthatói: [0.5692, -0.1258, 0.115, -0.0033, -0.0612, 0.1024, 0.084, -0.1041, 0.1342, -0.1304, 0.0798, -0.0514, 0.0174, 0.0038, -0.0067, 0.0162, 0.0533, -0.054, 0.047, -0.0238] $3.624314722364551e-06$. Az együtthatók a modell egyenletét jelentik, és azt mutatják, hogy az előző időszakok négyzetes visszatéréseinek milyen mértékben járulnak hozzá az aktuális négyzetes visszatérés előrejelzéséhez. Az eltérést a $3.624314722364551e-06$ értékű elfogadás mutatja.

Összességében úgy tűnik, hogy a lineáris regresszió modell a korábbi négyzetes hozamok alapján hatékonyan képes a jövőbeli variancia előrejelzésére. Az alacsony MSE egy jó illeszkedést sugall az adatokhoz, míg a koefficiensek betekintést nyújtanak a korábbi négyzetes hozamjellemzők hozzájárulásába. Mindazonáltal javasolt további elemzés és a modell teljesítményének értékelése különböző forgatókönyvekben és adatkészletekben annak hatékonyságának biztosítása érdekében.